

JOSÉ AUGUSTO SILVEIRA FERREIRA

ANÁLISE COMPARATIVA DE ALGORITMOS DE
APRENDIZADO DE MÁQUINA PARA PREVISÃO DA
EVASÃO ESCOLAR.

Relatório Técnico elaborado conforme a
ABNT NBR 10719:10, apresentado ao
Instituto Federal de Educação, Ciência
e Tecnologia de São Paulo, como parte
dos requisitos para a obtenção do
grau de Tecnólogo em Sistemas para
Internet.

Área de Concentração: Ciência
de Dados.

Orientador: Prof. Dr. Arthur Emanuel
de Oliveira Carosia

SÃO JOÃO DA BOA VISTA

2025

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE SÃO PAULO - CÂMPUS SÃO JOÃO DA BOA VISTA	NOV	2025
Tecnologia em Sistemas para Internet Análise Comparativa de Algoritmos de Aprendizado de Máquina para Previsão da Evasão Escolar. José Augusto Silveira Ferreira e Prof. Dr. Arthur Emanuel de Oliveira Carosia		
Palavras-chave: Evasão Escolar, Aprendizado de Máquina, Previsão, Algoritmos Supervisionados, Inteligência Artificial.		32 páginas

Ficha Catalográfica elaborada pela Biblioteca Comunitária
“Wolgran Junqueira Ferreira” do Instituto Federal de São Paulo
Câmpus São João da Boa Vista

F383a Ferreira, José Augusto Silveira
 Análise comparativa de algoritmos de aprendizado de máquina
 para previsão da evasão escolar / José Augusto Silveira Ferreira;
 orientador: Arthur Emanuel de Oliveira Carosia. -- São João da Boa
 Vista, 2025.
 32 f. : il.

Trabalho de Conclusão de Curso (Tecnologia em Sistemas
para Internet) -- Instituto Federal de Educação, Ciência e
Tecnologia de São Paulo, São João da Boa Vista, 2025.

1. Aprendizado de computador. 2. Evasão escolar. 3. Algoritmos.
4. Inteligência artificial. I. Carosia, Arthur Emanuel de Oliveira,
orient. II. Título.

ATA N.º 102/2025 - DAE-SBV/DRG/SBV/IFSP

Ata de Defesa de Trabalho de Conclusão de Curso - Graduação

Na presente data realizou-se a sessão pública de defesa do Trabalho de Conclusão de Curso intitulado **Análise Comparativa de Algoritmos de Aprendizado de Máquina para Previsão da Evasão Escolar** apresentado(a) pelo(a) aluno(a) **José Augusto Silveira Ferreira (BV3033813)** do Curso **SUPERIOR EM TECNOLOGIA EM SISTEMAS PARA INTERNET**, Campus São João da Boa Vista. Os trabalhos foram iniciados às 21:00 pelo(a) Professor(a) presidente da banca examinadora, constituída pelos seguintes membros:

Membros	Aprovação
ARTHUR EMANUEL DE OLIVEIRA CAROSIA (Presidente/Orientador)	APROVADO
GABRIEL MARCELINO ALVES (Examinador 1)	APROVADO
PAULO JOSÉ EVARISTO DA SILVA (Examinador 2)	APROVADO

Observações:

A banca examinadora, tendo terminado a apresentação do conteúdo da monografia, passou à arguição do(a) candidato(a). Em seguida, os examinadores reuniram-se para avaliação e deram o parecer final sobre o trabalho apresentado pelo(a) aluno(a), tendo sido atribuído o seguinte resultado:

[X] Aprovado(a) [] Reprovado(a) Nota
(quando exigido): _____

Proclamados os resultados pelo presidente da banca examinadora, foram encerrados os trabalhos e, para constar, eu lavrei a presente ata que assino juntamente com os demais membros da banca examinadora.

Campus São João da Boa Vista, 5 de dezembro de 2025

Assinatura:

Documento assinado eletronicamente por:

- **Arthur Emanuel de Oliveira Carosia**, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 05/12/2025 12:45:13.
- **Gabriel Marcelino Alves**, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 05/12/2025 13:07:23.
- **Paulo Jose Evaristo da Silva**, PROFESSOR ENS BASICO TECN TECNOLOGICO, em 05/12/2025 14:00:03.

Este documento foi emitido pelo SUAP em 05/12/2025. Para comprovar sua autenticidade, faça a leitura do QRCode ao lado ou acesse <https://suap.ifsp.edu.br/autenticar-documento/> e forneça os dados abaixo:

Código Verificador: 1078302

Código de Autenticação: b4f600c57d



SUMÁRIO

1	INTRODUÇÃO	9
1.1	Motivação e Justificativa	9
1.2	Objetivos	10
2	FUNDAMENTAÇÃO TEÓRICA	11
2.1	Aprendizado de Máquina e Inteligência Artificial.	11
2.1.1	Aprendizado Supervisionado	11
2.1.2	Aprendizado Não Supervisionado	12
2.1.3	Algoritmos Fundamentais	12
2.1.3.1	Decision Tree	12
2.1.3.2	Random Forest	13
2.1.3.3	Regressão Logística	13
2.1.3.4	Support Vector Machine	14
2.1.3.5	Rede Neural Artificial	14
2.2	Evasão Escolar	14
2.2.1	Fatores Determinantes	15
2.2.2	Consequências	15
2.3	Trabalhos Correlatos	16
3	METODOLOGIA	17
3.1	Coleta e Pré-processamento dos dados	17
3.2	Análise exploratória dos dados e geração de gráficos-base	18
3.3	Treinamento dos algoritmos de aprendizado de máquina	20
3.3.1	Divisão dos Dados	20
3.3.1.1	Configuração e Treinamento dos Modelos	20
3.3.1.1.1	<i>Decision Tree</i>	21
3.3.1.1.2	<i>Random Forest</i>	21
3.3.1.1.3	Regressão Logística	22
3.3.1.1.4	<i>Support Vector Machine</i>	22
3.3.1.1.5	Rede Neural Artificial	23
3.4	Criação de métricas e avaliação	24
3.5	Análise e comparação dos resultados	25
4	RESULTADOS	26
4.1	Coeficiente de correlação de <i>Pearson</i>	26
4.2	Distribuição por gênero	27

4.3	Distribuição por status final	27
4.4	Resultados dos algoritmos	28
4.5	Análise Comparativa dos Resultados	29
5	CONCLUSÃO	31
	REFERÊNCIAS	32

RESUMO

O presente trabalho investiga a aplicação de algoritmos de aprendizado de máquina para prever a evasão escolar, fenômeno multifacetado com impactos socioeconômicos significativos. São comparados cinco modelos supervisionados — Decision Tree, Random Forest, Regressão Logística, Support Vector Machine (SVM) e Rede Neural Artificial — utilizando dados educacionais do repositório UC *Irvine*. A metodologia inclui coleta e pré-processamento de dados, análise exploratória, treinamento e avaliação com base em métricas de precisão, *recall* e *F1-score*. O estudo visa identificar o modelo mais eficaz para antecipar comportamentos de risco e contribuir para estratégias preventivas na educação.

Palavras-chave: Evasão Escolar, Aprendizado de Máquina, Previsão, Algoritmos Supervisionados, Inteligência Artificial.

1 INTRODUÇÃO

1.1 Motivação e Justificativa

A evasão escolar representa um dos desafios mais complexos e persistentes enfrentados pelos sistemas educacionais atuais, tanto no Brasil quanto globalmente. Caracterizada pela interrupção prematura dos estudos em qualquer etapa do ensino básico ou superior, este fenômeno vai além da simples desistência individual, configurando-se como um problema estrutural com profundas implicações socioeconômicas e culturais (Lino, 2020). No contexto brasileiro, dados do Censo Escolar revelam que aproximadamente 2 milhões de estudantes abandonam as salas de aula anualmente, comprometendo não apenas suas trajetórias individuais, mas também o desenvolvimento educacional coletivo e a formação de capital humano necessário para o avanço social e econômico do país (Santillana Educação, 2025).

As consequências da evasão escolar manifestam-se em múltiplas dimensões. No âmbito individual, o abandono dos estudos prejudica significativamente a inserção e ascensão no mercado de trabalho, limitando oportunidades profissionais e perpetuando ciclos de vulnerabilidade socioeconômica. Em escala mais ampla, o fenômeno contribui para o aprofundamento das desigualdades sociais, compromete a eficiência dos investimentos públicos em educação e impacta negativamente indicadores de desenvolvimento humano (Kabathova; Drlik, 2021). Segundo estimativas da Singla et al. (2025), cada estudante que abandona o sistema educacional representa uma perda econômica potencial que pode ultrapassar centenas de milhares de reais ao longo da vida produtiva, considerando-se a redução na capacidade de geração de renda e contribuição fiscal.

A complexidade causal da evasão escolar demanda uma compreensão multifatorial. Levantamento realizado por Lino (2020) identifica um espectro diversificado de fatores determinantes, incluindo condições socioeconômicas desfavoráveis, gravidez na adolescência, envolvimento com substâncias psicoativas, fragilização dos vínculos familiares, dificuldades de aprendizagem não diagnosticadas, *bullying* e violência escolar, além de questões institucionais como infraestrutura inadequada e práticas pedagógicas pouco inclusivas. Esta multiplicidade de causas evidencia que intervenções eficazes necessitam de abordagens igualmente complexas e personalizadas, capazes de identificar precocemente estudantes em situação de vulnerabilidade.

1.2 Objetivos

Diante deste contexto, o presente trabalho tem como objetivo analisar e comparar o desempenho de cinco algoritmos de aprendizado de máquina na previsão da evasão escolar, visando identificar o modelo mais preciso e contribuir para o desenvolvimento de estratégias preventivas baseadas em evidências. Os algoritmos selecionados para este estudo representam diferentes abordagens dentro do campo do aprendizado supervisionado, conforme classificação proposta por Osisanwo et al. (2017): Árvore de Decisão (*Decision Tree*), que utiliza estruturas hierárquicas para classificação; Floresta Aleatória (*Random Forest*), que combina múltiplas árvores de decisão para reduzir o risco de *overfitting*; Regressão Logística (*Logistic Regression*), que modela a probabilidade de ocorrência da evasão por meio da função logística, permitindo a classificação binária dos estudantes em “evadidos” e “não evadidos”; *Support Vector Machine* (SVM), que busca hiperplanos ótimos para separação de classes; e Rede Neural Artificial, que simula estruturas neurobiológicas para identificação de padrões complexos.

2 FUNDAMENTAÇÃO TEÓRICA

Neste cenário desafiador, as tecnologias baseadas em inteligência artificial, particularmente o aprendizado de máquina, surgem como ferramentas promissoras para a compreensão e enfrentamento da evasão escolar. A capacidade destes sistemas de processar e analisar grandes volumes de dados educacionais, identificando padrões e correlações não evidentes por métodos tradicionais, possibilita a construção de modelos preditivos capazes de identificar precocemente estudantes em risco de abandono (Sulak; Koklu, 2024). Esta detecção antecipada viabiliza a implementação de intervenções preventivas personalizadas, potencialmente mais eficazes e economicamente eficientes que estratégias reativas.

2.1 Aprendizado de Máquina e Inteligência Artificial.

O aprendizado de máquina (*Machine Learning* - ML) representa um subcampo da inteligência artificial (IA) dedicado ao desenvolvimento de algoritmos e modelos estatísticos que permitem aos sistemas computacionais aprimorarem seu desempenho em determinadas tarefas por meio da experiência, sem necessidade de programação explícita. A inteligência artificial constitui um domínio mais amplo da ciência da computação dedicado ao desenvolvimento de sistemas capazes de realizar tarefas que, tradicionalmente, demandam inteligência humana, como reconhecimento visual, compreensão de linguagem natural, tomada de decisões e resolução de problemas complexos (IBM; Stryker, 2024).

Os algoritmos de aprendizado de máquina são tradicionalmente categorizados em diferentes tipos, conforme a forma dos dados disponíveis e os objetivos de aprendizagem. Os principais tipos incluem:

2.1.1 Aprendizado Supervisionado

O aprendizado supervisionado constitui a abordagem mais comum e intuitiva, caracterizada pelo treinamento de modelos com dados rotulados, onde cada exemplo de entrada está associado a uma saída desejada. O objetivo essencialmente é que o algoritmo aprenda uma função de mapeamento capaz de prever corretamente os rótulos de novos dados não observados durante o treinamento, caracterizados como algoritmos de classificação ou regressão. A classificação é aplicada quando a variável de saída é categórica (ou discreta), como nos casos de identificação de mensagens de *spam* em e-mails, diagnóstico de doenças ou reconhecimento de objetos em imagens. Para esse tipo de tarefa, utilizam-se algoritmos como *Decision Tree*, *Random Forest*, *Support Vector Machine* (SVM) e Redes Neurais (Osisanwo et al., 2017). Por outro lado, a regressão é empregada quando a variável de

saída é contínua, sendo útil em cenários como a previsão de preços de imóveis, a estimativa de vendas ou a projeção de temperatura. (IBM, s.d).

2.1.2 Aprendizado Não Supervisionado

Diferentemente do aprendizado supervisionado, o aprendizado não supervisionado opera sobre conjuntos de dados que não possuem rótulos ou saídas pré-definidas associadas às entradas. O objetivo central desta abordagem é descobrir estruturas, padrões ou conhecimentos ocultos nos próprios dados, sem a orientação de um resultado esperado (Russell; Norvig, 2013). Os algoritmos de aprendizado não supervisionado exploram as características dos dados para identificar agrupamentos naturais, reduzir a dimensionalidade ou encontrar associações relevantes. Uma das tarefas mais comuns no aprendizado não supervisionado é o agrupamento (*clustering*), que visa particionar o conjunto de dados em grupos (*clusters*), de modo que os pontos de dados dentro de um mesmo grupo sejam mais similares entre si do que com os pontos de dados de outros grupos (Russell; Norvig, 2013).

2.1.3 Algoritmos Fundamentais

A diversidade de algoritmos de aprendizado de máquina reflete a multiplicidade de problemas e contextos onde esta tecnologia é aplicada. Compreender os principais algoritmos mais relevantes é essencial para sua aplicação eficaz em problemas específicos. Dentre os algoritmos que serão utilizados neste trabalho estão: Decision Tree, Random Forest, Regressão Logística, Support Vector Machine e Rede Neural Artificial.

2.1.3.1 Decision Tree

A Árvore de Decisão (*Decision Tree*) é um modelo de aprendizado supervisionado não paramétrico utilizado tanto para tarefas de classificação quanto de regressão. Sua estrutura assemelha-se a um fluxograma, onde cada nó interno representa um teste em um atributo (*feature*), cada ramo representa o resultado do teste e cada nó folha representa um rótulo de classe (em classificação) ou um valor numérico (em regressão) (Russell; Norvig, 2013). O processo de decisão inicia na raiz da árvore e segue um caminho descendente, aplicando os testes nos nós internos de acordo com os valores dos atributos da instância a ser classificada ou prevista, até alcançar um nó folha que determina a saída do modelo. A construção da árvore geralmente envolve um processo recursivo de particionamento do conjunto de dados, selecionando em cada etapa o atributo e o ponto de corte que melhor dividem os dados com base em critérios como ganho de informação ou distribuição dos dados (Índice *Gini*). As Árvores de Decisão são valorizadas por sua interpretabilidade, pois as regras de decisão podem ser facilmente visualizadas e compreendidas. No entanto, são suscetíveis ao super ajustamento (*overfitting*), especialmente com árvores profundas, o

que pode ser mitigado por técnicas como poda ou o uso de *ensembles* (Osisanwo et al., 2017).

2.1.3.2 Random Forest

A Floresta Aleatória (*Random Forest*) é um algoritmo de aprendizado de máquina baseado no conceito de *ensemble learning*, especificamente utilizando a técnica de *bagging* (*Bootstrap Aggregating*) combinada com a aleatorização na seleção de atributos (Russell; Norvig, 2013). Essencialmente, uma Random Forest constroi múltiplas Árvores de Decisão durante o treinamento e combina suas previsões para obter uma classificação ou regressão final mais robusta e precisa. Cada árvore na floresta é treinada em uma amostra diferente do conjunto de dados original, obtida através de amostragem *bootstrap* (com reposição). Além disso, em cada nó da árvore, ao invés de considerar todos os atributos para encontrar a melhor divisão, apenas um subconjunto aleatório de atributos é considerado. Essa dupla aleatoriedade (nas amostras e nos atributos) contribui para a diversidade entre as árvores, reduzindo a variância do modelo e diminuindo significativamente o risco de *overfitting*, um problema comum em árvores de decisão individuais (Osisanwo et al., 2017). A previsão final é geralmente obtida pela moda das previsões das árvores individuais (para classificação) ou pela média (para regressão).

2.1.3.3 Regressão Logística

A Regressão Logística é um algoritmo fundamental do aprendizado supervisionado, utilizado primariamente em tarefas de classificação, ou seja, para prever a probabilidade de uma instância pertencer a uma determinada classe. Diferentemente da Regressão Linear, que modela uma relação linear para prever um valor contínuo, a Regressão Logística emprega a mesma estrutura linear, mas aplica uma função de ligação para restringir a saída a um intervalo entre 0 e 1.

Esta função de ligação é a função logística, que transforma a combinação linear das variáveis preditoras em uma probabilidade. O resultado desta transformação é interpretado como a probabilidade de a variável dependente pertencer à classe positiva.

O objetivo do treinamento é encontrar os coeficientes que maximizem a verossimilhança (ou minimizem a função de custo, tipicamente a **log loss** ou entropia cruzada) entre as probabilidades previstas e os rótulos de classe reais. Embora o nome sugira "regressão", o modelo é um classificador robusto e eficiente, sendo a base para a classificação binária e podendo ser estendido para problemas de classificação multi-classe. (Russell; Norvig, 2013; Hastie; Tibshirani; Friedman, 2009).

2.1.3.4 Support Vector Machine

A Máquina de Vetores de Suporte (*Support Vector Machine - SVM*) é um poderoso algoritmo de aprendizado supervisionado utilizado principalmente para tarefas de classificação, embora também possa ser adaptado para regressão (Russell; Norvig, 2013). O objetivo fundamental do SVM é encontrar um hiperplano ótimo que separe as diferentes classes no espaço de características com a maior margem possível. A margem é definida como a distância entre o hiperplano de separação e os pontos de dados mais próximos de cada classe, conhecidos como vetores de suporte. Ao maximizar a margem, o SVM busca uma solução que generalize bem para novos dados. Uma das grandes vantagens do SVM é sua capacidade de lidar com dados não linearmente separáveis através do "truque do kernel" (*kernel trick*). *Kernels* são funções que mapeiam os dados para um espaço de características de dimensão superior, onde a separação linear pode ser possível. *Kernels* comuns incluem o linear, polinomial, e a função de base radial (RBF). O SVM é eficaz em espaços de alta dimensão e robusto contra *overfitting*, especialmente quando o número de dimensões é maior que o número de amostras (Osisanwo et al., 2017).

2.1.3.5 Rede Neural Artificial

As Redes Neurais Artificiais (*Artificial Neural Networks - ANNs*) são modelos computacionais inspirados na estrutura e funcionamento do cérebro humano, compostos por unidades de processamento interconectadas chamadas neurônios artificiais, organizadas em camadas (RUSSELL; NORVIG, 2013). Uma ANN típica possui uma camada de entrada (onde os dados são introduzidos), uma ou mais camadas ocultas (onde ocorrem as computações intermediárias) e uma camada de saída (que produz o resultado final, como uma classificação ou um valor de regressão). Cada conexão entre neurônios possui um peso associado, que é ajustado durante o processo de treinamento através de algoritmos como o *backpropagation*, com o objetivo de minimizar o erro entre as previsões da rede e os valores reais. As ANNs são capazes de aprender representações complexas e não lineares dos dados, tornando-as adequadas para uma vasta gama de tarefas, incluindo reconhecimento de padrões, processamento de linguagem natural e previsão. A profundidade (número de camadas) e a largura (número de neurônios por camada) da rede definem sua arquitetura e capacidade de aprendizado (Osisanwo et al., 2017).

2.2 Evasão Escolar

A evasão escolar, compreendida como a interrupção da trajetória educacional antes da conclusão de um determinado nível de ensino (seja básico ou superior), transcende a esfera individual para se configurar como um fenômeno social complexo com ramificações profundas (LINO, 2020). Não se trata apenas de uma decisão isolada do estudante, mas

frequentemente reflete um conjunto de barreiras e dificuldades sistêmicas e pessoais que resultam no abandono dos estudos. No Brasil, a magnitude do problema é alarmante, com milhões de jovens e adultos deixando a escola anualmente, o que impacta diretamente o desenvolvimento do capital humano nacional e a capacidade do país de promover mobilidade social e crescimento econômico sustentável (Santillana Educação, 2025). A persistência de altas taxas de evasão evidencia a necessidade urgente de estratégias eficazes que não apenas identifiquem os estudantes em risco, mas que também abordem as causas multifacetadas que levam ao abandono escolar.

2.2.1 Fatores Determinantes

A compreensão dos fatores que levam à evasão escolar é crucial para o desenvolvimento de intervenções preventivas eficazes. A literatura aponta consistentemente para uma natureza multifatorial e interconectada das causas do abandono (Lino, 2020). Fatores socioeconômicos desempenham um papel significativo, incluindo baixa renda familiar, necessidade de trabalhar precocemente para complementar a renda doméstica e falta de recursos básicos que afetam a capacidade de concentração e participação nas atividades escolares. Questões pessoais e familiares, como gravidez na adolescência, desestruturação familiar, falta de apoio dos pais ou responsáveis e problemas de saúde (física ou mental), também contribuem substancialmente para o risco de evasão. Dentro do ambiente escolar, dificuldades de aprendizagem não diagnosticadas ou não adequadamente tratadas, metodologias de ensino pouco engajadoras, currículos desconectados da realidade dos alunos, problemas de relacionamento com colegas (como bullying) ou professores, e a percepção de um ambiente escolar inseguro ou pouco acolhedor são fatores relevantes (Lino, 2020; Kabathova; Drlik, 2021). Além disso, fatores externos como envolvimento com atividades ilícitas ou uso de substâncias psicoativas podem afastar o estudante do percurso educacional. A complexidade reside na interação desses múltiplos fatores, que variam em intensidade e combinação para cada indivíduo.

2.2.2 Consequências

As consequências da evasão escolar são vastas e impactam negativamente tanto o indivíduo quanto a sociedade como um todo. Para o estudante que abandona a escola, as perspectivas de inserção qualificada no mercado de trabalho são drasticamente reduzidas, levando frequentemente a empregos precários, baixos salários e maior vulnerabilidade socioeconômica ao longo da vida (Lino, 2020). A falta de qualificação formal limita as oportunidades de ascensão profissional e contribui para a perpetuação de ciclos de pobreza intergeracional. Em um nível macro, a evasão escolar representa um desperdício significativo de investimento público em educação, comprometendo a eficiência do sistema educacional. Além disso, contribui para o aumento das desigualdades sociais, uma vez que

afeta desproporcionalmente grupos já vulnerabilizados. A redução do nível educacional médio da população impacta negativamente a produtividade nacional, a capacidade de inovação e o desenvolvimento de uma cidadania plena e participativa (Kabathova; Drlik, 2021). Estimativas econômicas, como as mencionadas por Singla et al. (2025), quantificam a perda potencial associada a cada estudante evadido em termos de menor geração de renda e contribuição fiscal, evidenciando o alto custo social e econômico do fenômeno.

2.3 Trabalhos Correlatos

A literatura especializada tem documentado experiências promissoras na aplicação de algoritmos de aprendizado de máquina para a previsão da evasão escolar em diferentes contextos educacionais. Kabathova e Drlik (2021) demonstraram que modelos preditivos baseados em dados acadêmicos e comportamentais podem alcançar níveis de precisão superiores a 85% na identificação de estudantes universitários em risco de abandono. Similarmente, Sulak e Koklu (2024) evidenciaram que a combinação de variáveis socioeconômicas, psicológicas e de desempenho acadêmico em modelos de aprendizado supervisionado permite identificar padrões complexos que precedem a decisão de abandono, possibilitando intervenções preventivas personalizadas.


Outro trabalho relevante é o de Osisanwo et al. (2017), que propuseram uma comparação sistemática entre diferentes algoritmos de classificação, como Árvores de Decisão, Floresta Aleatória, SVM e Redes Neurais, aplicados a problemas de evasão escolar e outras áreas. O estudo evidenciou que não existe um algoritmo universalmente superior, sendo a escolha dependente das características do conjunto de dados, do balanceamento das classes e dos objetivos da análise, como maximizar precisão, *recall* ou *F1-score*.

Em síntese, os trabalhos correlatos convergem na utilização de aprendizado de máquina como ferramenta promissora para a previsão da evasão escolar, destacando a necessidade de abordagens comparativas entre algoritmos, a importância da qualidade e diversidade dos dados, e o potencial de impacto na formulação de políticas educacionais preventivas. O presente estudo se insere nesse contexto ao propor uma análise comparativa de cinco algoritmos supervisionados, contribuindo para o avanço do conhecimento e da prática na área.

3 METODOLOGIA

Esta seção detalha a abordagem metodológica empregada para atingir os objetivos propostos neste trabalho, que consistem em analisar e comparar o desempenho de diferentes algoritmos de aprendizado de máquina na previsão da evasão escolar. A metodologia abrange desde a coleta e pré-processamento dos dados até o treinamento, avaliação e comparação dos modelos.

Figura 1 – Fluxograma da Metodologia



Fonte: Elaborada pelo autor

3.1 Coleta e Pré-processamento dos dados

Para o desenvolvimento e treinamento dos modelos de aprendizado de máquina, serão utilizados dados educacionais provenientes do repositório *UC Irvine Machine Learning Repository*. A seleção do conjunto de dados específico será baseada em sua relevância para o problema da evasão escolar, disponibilidade de atributos pertinentes (demográficos, acadêmicos, socioeconômicos, etc.) e adequação ao volume necessário para o treinamento eficaz dos algoritmos. Caso seja necessário, será realizada uma busca por conjuntos de

dados complementares que possam enriquecer a análise e a capacidade preditiva dos modelos.

O processo de pré-processamento dos dados é crucial para garantir a qualidade e a consistência do conjunto de dados, otimizando o desempenho dos modelos. As etapas incluirão:

Normalização ou padronização de variáveis numéricas para garantir que todas as características contribuam de forma equitativa para o treinamento do modelo, evitando que características com escalas maiores dominem o processo.

Seleção e Engenharia de Atributos (*Feature Engineering*): Análise da relevância dos atributos existentes e, se aplicável, criação de novas características a partir das existentes que possam melhorar a capacidade preditiva dos modelos. Esta etapa pode envolver a redução de dimensionalidade para otimizar o tempo de processamento e evitar o *overfitting*.

A plataforma escolhida para a implementação dos códigos e manipulação dos dados será o *Google Collaboratory (Google Colab)*, devido à sua acessibilidade, ambiente de desenvolvimento baseado em nuvem e suporte a bibliotecas de aprendizado de máquina em Python. Os dados serão carregados a partir de arquivos no formato CSV.

O carregamento inicial foi realizado com o seguinte código:

Código 3.1 – Carregamento dos dados em CSV no Python.

```
1 df = pd.read_csv("/content/drive/MyDrive/_TCC/data.csv", sep = ';')
2 df
```

Durante a análise exploratória, identificou-se a necessidade de um pequeno ajuste no nome de uma coluna que continha um caractere de tabulação (`\t`), o que poderia comprometer a manipulação futura.

Código 3.2 – Remoção do "`\t`" em nome de coluna.

```
1
2 df.columns = [col.strip().replace('\t', '') for col in df.columns]
```

Essa foi a única manipulação necessária nos dados, pois, com exceção dos dados de evasão escolar, todos eram valores numéricos.

3.2 Análise exploratória dos dados e geração de gráficos-base

Após o pré-processamento, será realizada uma análise exploratória dos dados (EDA - *Exploratory Data Analysis*) para compreender a distribuição das variáveis, identificar correlações, detectar *outliers* e obter observações preliminares sobre o conjunto de dados. Esta etapa é fundamental para guiar as decisões nas fases subsequentes do projeto.

Serão gerados diversos gráficos base para visualização e compreensão dos dados, incluindo, mas não se limitando a: Gráficos de barras, dispersão e linha, permitindo analisar a distribuição de variáveis categóricas, identificação de relações entre pares de variáveis e análise de tendências.

- Gráficos de Barras: Para analisar a distribuição de variáveis categóricas.
- Gráficos de Dispersão (*Scatter Plots*): Para identificar relações entre pares de variáveis.
- Mapas de Calor (*Heatmaps*) de Matrizes de Correlação: Para visualizar a correlação entre todas as variáveis do conjunto de dados, auxiliando na identificação de características redundantes ou importantes.

Código 3.3 – Gráfico de Distribuição por gênero.

```

1 male_data = df[df['Gender'] == 1]['Target'].value_counts()
2 female_data = df[df['Gender'] == 0]['Target'].value_counts()
3
4 # Cores
5 colors = ['#ff9999', '#66b3ff', '#99ff99']
6 colors_m = ['#ff9999', '#66b3ff', '#99ff99']
7 colors_f = ['#66b3ff', '#ff9999', '#99ff99']
8
9 fig, axes = plt.subplots(1, 2, figsize=(12, 6))
10
11 # Grafico masculino
12 axes[0].pie(male_data, labels=male_data.index, autopct='%1.1f%%',
13             startangle=90, colors=colors)
14 axes[0].set_title('Distribuição - Homens')
15
16 # Grafico feminino
17 axes[1].pie(female_data, labels=female_data.index, autopct='%1.1f%%',
18             startangle=90, colors=colors_f)
19 axes[1].set_title('Distribuição - Mulheres')
20
21 # Garante que os circulos fiquem perfeitos
22 plt.tight_layout()
23 plt.show()

```

Código 3.4 – Gráfico de Distribuição geral.

```

1 sns.countplot(data=df, x='Target')
2 plt.title("Distribuição dos Alunos por Status Final")
3 plt.xticks(rotation=0)
4 plt.ylabel("Contagem")
5 plt.xlabel("Status")
6 plt.show()

```

Código 3.5 – Matriz de correlação de Pearson

```
1
2 # Pearson
3 corr = df.select_dtypes(include=np.number).corr()
4
5 plt.figure(figsize=(16, 12)) # Aumenta o tamanho do grafico
6 sns.heatmap(
7     corr,
8     annot=True,
9     fmt=".2f",
10    cmap='coolwarm',
11    linewidths=0.8,          # Espaco entre celulas
12    annot_kws={'size': 7}    # Tamanho dos numeros
13 )
14 plt.title("Matriz de Correlacao Pearson", fontsize=14)
15 plt.xticks(rotation=90)
16 plt.yticks(rotation=0)
17 plt.tight_layout() # Ajusta tudo para caber bem
18 plt.show()
```

3.3 Treinamento dos algoritmos de aprendizado de máquina

Esta etapa envolve a aplicação dos algoritmos de aprendizado de máquina selecionados para o problema de previsão da evasão escolar. Os algoritmos a serem treinados e comparados são: (*Decision Tree*), (*Random Forest*), Regressão Logística, Support Vector Machine (SVM) e Rede Neural Artificial (*Artificial Neural Network*).

O processo de treinamento seguirá as seguintes fases:

3.3.1 Divisão dos Dados

O conjunto de dados pré-processados serão utilizados para: treinamento, validação e teste. O conjunto de treinamento será utilizado para ajustar os parâmetros dos modelos, o conjunto de validação para otimizar hiperparâmetros e evitar *overfitting* durante o desenvolvimento, e o conjunto de teste, mantido intocado até o final, para uma avaliação imparcial do desempenho final dos modelos.

3.3.1.1 Configuração e Treinamento dos Modelos

Cada algoritmo será configurado com seus parâmetros iniciais e treinado utilizando o conjunto de dados de treinamento. Serão utilizadas bibliotecas de aprendizado de máquina em Python, como *scikit-learn* para os modelos tradicionais e, possivelmente, *TensorFlow* ou *Keras* para a Rede Neural Artificial.

3.3.1.1.1 Decision Tree

O modelo de Árvore de Decisão foi implementado com uma profundidade máxima (*max_depth*) limitada a , visando evitar o *overfitting* aos dados de treino.

Código 3.6 – Árvore de Decisão

O código separa as *features* (*X*) do alvo (*y*), divide os dados (% treino, % teste), instancia o *DecisionTreeClassifier* usando o critério *Gini* e treina o modelo (*modelo_dt.fit*). A avaliação é feita com a Acurácia e o Relatório de Classificação, que detalha as métricas para cada classe.

3.3.1.1.2 Random Forest

Código 3.7 – Random Forest

```

1
2 # Criando o modelo
3 X = df.drop("Target", axis=1)
4 y = df["Target"]
5
6 # Transformar o Target em numeros
7 le = LabelEncoder()
8 y = le.fit_transform(y) # (Exemplo: Dropout=0, Enrolled=1, Graduate=2)
9
10 # Divisao modelo/teste
11 X_train, X_test, y_train, y_test = train_test_split(
12     X, y, test_size=0.2, random_state=42
13 )
14
15 modelo_rf = RandomForestClassifier(
16     n_estimators=100,          # numero de arvores
17     max_depth=None,           # profundidade das arvores
18     random_state=42,
19     n_jobs=-1                 # usa todos os nucleos do processador
20 )
21
22 modelo_rf.fit(X_train, y_train)
23 y_pred = modelo_rf.predict(X_test)
24 print("Acuracia:", accuracy_score(y_test, y_pred))
25 print("\nRelatorio de classificacao:\n", classification_report(y_test,
26     y_pred, target_names=le.classes_))
27
28 # Matriz de confusao
29 sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, fmt="d", cmap=
30     "Blues",

```

```

29         xticklabels=le.classes_, yticklabels=le.classes_)
30 plt.xlabel("Previsto")
31 plt.ylabel("Real")
32 plt.show()

```

O *LabelEncoder* é usado para converter a variável alvo em números. O modelo é treinado e avaliado.

3.3.1.1.3 Regressão Logística

Código 3.8 – Regressão Logística

```

1
2 # Copiar o DataFrame original
3 dados = df.copy()
4
5 # Definir X (variaveis independentes) e y (variavel alvo)
6 X = dados.drop('Target', axis=1)
7 y = dados['Target']
8
9 # Dividir a base em treino e teste
10 X_train, X_test, y_train, y_test = train_test_split(
11     X, y, test_size=0.2, random_state=42, stratify=y
12 )
13
14 # Criar e treinar o modelo de Regressão Logística
15 modelo = LogisticRegression(max_iter=1000)
16 modelo.fit(X_train, y_train)
17
18 # Fazer previsoes
19 y_pred = modelo.predict(X_test)
20
21 # Avaliar o modelo
22 print("Acurácia:", accuracy_score(y_test, y_pred))
23 print("\

```

O parâmetro *max_iter=* foi definido para garantir que o algoritmo de otimização tivesse iterações suficientes para convergir. O uso de *stratify=y* na divisão dos dados é um ponto de destaque, pois preserva a distribuição das classes

3.3.1.1.4 Support Vector Machine

Foram feitos diversos testes com *kernels* diferentes, e o SVM foi implementado com um *kernel* linear (*kernel='linear'*), pois foi o que apresentou resultados mais satisfatórios, buscando a separação das classes por um hiperplano.

Código 3.9 – Support Vector Machine - SVM

```

1
2 # Separar as variaveis (X) e o alvo (y)
3 X = df.drop(columns=['Target'])
4 y = df['Target']
5
6 # Dividir em treino e teste (70\% treino, 30\% teste)
7 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
8     random_state=42)
9
10 # Criar e treinar o modelo SVM
11 svm = SVC(kernel='linear', random_state=42) #Criacao
12 svm.fit(X_train, y_train) # Treino
13 y_pred = svm.predict(X_test) # Previsao
14
15 # Avaliar o desempenho
16 print("\n SUPPORT VECTOR MACHINE")
17 print("Acurácia:", accuracy_score(y_test, y_pred))
18 print("Precisão:", precision_score(y_test, y_pred, average='macro'))
19 print("Recall:", recall_score(y_test, y_pred, average='macro'))
20 print("F1-score:", f1_score(y_test, y_pred, average='macro'))

```

A divisão dos dados foi alterada para % treino e % teste. A avaliação utiliza o parâmetro *average='macro'* nas métricas de Precisão, *Recall* e *F1-score*. Este parâmetro calcula a média não ponderada das métricas para cada classe, garantindo que o desempenho em classes minoritárias tenha o mesmo peso que as classes majoritárias, o que é fundamental para uma avaliação justa em classificação multi-classe.

3.3.1.1.5 Rede Neural Artificial

A Rede Neural (*MLPClassifier*) foi configurada com uma arquitetura profunda, mas compacta.

Código 3.10 – Rede Neural Artificial

```

1
2 # Separar as variaveis (X) e o alvo (y)
3 X = df.drop(columns=['Target'])
4 y = df['Target']
5
6 # Dividir em treino e teste (70\% treino, 30\% teste)
7 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
8     random_state=42)
9
10 # Criar a Rede Neural
11 # hidden_layer_sizes define o numero de camadas e neuronios em cada uma

```

```
11 mlp = MLPClassifier(hidden_layer_sizes=(5,5,5,5,5,5,5,5), max_iter=1000,
    random_state=42)
12
13 # Treinar o modelo
14 mlp.fit(X_train, y_train)
15
16 # Fazer previsoes
17 y_pred = mlp.predict(X_test)
18
19 # Avaliar o desempenho
20 print("\n--- REDE NEURAL ARTIFICIAL ---")
21 print("Acuracia:", accuracy_score(y_test, y_pred))
22 print("Precisao:", precision_score(y_test, y_pred, average='macro'))
23 print("Recall:", recall_score(y_test, y_pred, average='macro'))
24 print("F1-score:", f1_score(y_test, y_pred, average='macro'))
```

O parâmetro `hidden_layer_sizes = (5,5,5,5,5,5,5,5)` define uma arquitetura com oito camadas ocultas, cada uma com cinco neurônios. Esta configuração explora o conceito de *Deep Learning* (Aprendizado Profundo), embora com um número reduzido de neurônios. O `max_iter=1000` permite um treinamento mais longo para a convergência da rede. Foram feitos diversos testes com diferentes quantidades de camadas e neurônios, e essa foi a configuração com resultado mais satisfatório.

3.4 Criação de métricas e avaliação

A avaliação do desempenho dos modelos é uma etapa crítica para determinar sua eficácia na previsão da evasão escolar. Serão utilizadas métricas de avaliação específicas para problemas de classificação binária, considerando a natureza do problema (prever se um aluno evadirá ou não).

As métricas principais a serem consideradas, conforme mencionado nos objetivos, são:

Precisão (*Precision*): Mede a proporção de verdadeiros positivos entre todas as previsões positivas feitas pelo modelo. É crucial para minimizar falsos positivos, ou seja, classificar incorretamente um aluno que não evadiria como evadido.

Recall: Mede a proporção de verdadeiros positivos que foram corretamente identificados pelo modelo entre todos os positivos reais. É importante para minimizar falsos negativos, ou seja, não identificar um aluno que evadiria.

F1-Score: Representa a média harmônica entre Precisão e *Recall*, oferecendo uma medida balanceada do desempenho do modelo, especialmente útil em casos de desequilíbrio de classes (onde o número de alunos evadidos é significativamente menor que o de não

evadidos).

A escolha e a interpretação das métricas levarão em conta o contexto do problema da evasão escolar, onde tanto falsos positivos quanto falsos negativos possuem implicações significativas para as intervenções preventivas.

3.5 Análise e comparação dos resultados

Nesta etapa, os resultados obtidos por cada algoritmo de aprendizado de máquina serão sistematicamente analisados e comparados com base nas métricas de avaliação definidas na seção anterior. O objetivo é identificar o modelo que apresenta o melhor desempenho preditivo para o problema da evasão escolar.

A comparação será realizada da seguinte forma:

Análise Quantitativa: Os valores de Precisão, *Recall*, *F1-Score* (e outras métricas complementares) de cada modelo serão tabulados e visualizados em gráficos comparativos para facilitar a identificação do modelo com o melhor desempenho geral e em aspectos específicos.

Análise Qualitativa: Será discutida a interpretabilidade de cada modelo, a complexidade computacional e a robustez frente a diferentes cenários. Por exemplo, enquanto Redes Neurais podem oferecer alta precisão, Árvores de Decisão e Florestas Aleatórias podem ser mais fáceis de interpretar, o que é valioso para a formulação de políticas educacionais.

Identificação do Modelo Ideal: Com base na análise quantitativa e qualitativa, será determinado qual algoritmo se mostra mais adequado para a previsão da evasão escolar, considerando não apenas a acurácia, mas também a aplicabilidade prática e a interpretabilidade dos resultados para as instituições de ensino.

Os resultados desta análise serão apresentados de forma clara e concisa, utilizando tabelas para ilustrar as comparações e as conclusões obtidas.


4 RESULTADOS

Foi feito um estudo prévio das variáveis na fonte de dados para analisar possíveis correlações e informações, utilizando gráficos e algoritmos de análise de correlação, como Matriz de correlação de *Pearson* ou *Spearman* e Gráfico de Pizza.

4.1 Coeficiente de correlação de *Pearson*

Foi feita uma matriz de correlação, utilizando o coeficiente de correlação de *Pearson*. O coeficiente varia entre -1 e +1, sendo que valores próximos a +1 indicam forte correlação positiva, próximos a -1 indicam forte correlação negativa, e valores próximos de 0 sugerem ausência de correlação linear significativa. Trata-se de um método sensível à presença de *outliers*, que podem distorcer os resultados.

Figura 2 – Matriz de correlação de *Pearson*



Fonte: Elaborada pelo autor

A variável *International* tem correlações próximas de zero com as demais, indicando que alunos internacionais são poucos ou muito variados em comportamento nesta base de

dados.


Algumas correlações negativas se destacam, como *Gender* e *Scholarship Holder*, com uma correlação de -0,1, o que pode indicar que, proporcionalmente, há diferença de gênero no recebimento de bolsas estudantis entre os alunos analisados.

As variáveis *GPD* e *Employment Rate* tem correlação negativa, o que pode indicar que a situação financeira possui impacto na graduação dentre os estudantes desta base de dados.

4.2 Distribuição por gênero

Foi gerado um gráfico de Pizza para analisar a distribuição de gênero entre alunos Graduados, Matriculados e Evadidos:

Figura 3 – Distribuição por gênero




Fonte: Elaborada pelo autor

O gráfico mostra uma diferença entre Graduado e Evadido em homens e mulheres nesta base de dados, onde a maioria das mulheres se formam, enquanto a maioria dos homens evadem ou reprovam. Isso pode indicar diferenças entre gênero e permanência nos estudos.

4.3 Distribuição por status final

Foi gerado um gráfico de barra para analisar a distribuição de alunos Graduados, Matriculados e Evadidos de maneira geral:

Figura 4 – Distribuição por resultado final



Fonte: Elaborada pelo autor

O gráfico mostra que, de acordo com a base de dados analisada, a maioria dos alunos completa a graduação, enquanto mais da metade dos que se formam, abandonam os estudos. Metade dos alunos que evadem, continuam matriculados, mas ainda não se formaram.

4.4 Resultados dos algoritmos

Os resultados de desempenho dos cinco modelos foram consolidados na Figura 5, focando nas métricas de avaliação para a classe *Dropout*, que é a classe de maior interesse para intervenção institucional.

Figura 5 – Tabela de Resultados

Resultados Finais				
	Acurácia	Precision (Evasão)	Recall (Evasão)	F1-score (Evasão)
Decision Tree	0,73	0,85	0,68	0,76
Random Forest	0,76	0,85	0,77	0,81
Regressão Logística	0,72	0,73	0,71	0,72
Support Vector Machine	0,75	0,69	0,65	0,65
Rede Neural Artificial	0,73	0,69	0,62	0,61
Média	0,74	0,76	0,69	0,71

Fonte: Elaborada pelo autor

Análise e Interpretação das Métricas: A análise dos resultados deve ser focada no *F1-score* para a classe *Dropout*, pois esta métrica representa o equilíbrio entre a Precisão e o *Recall*, sendo ideal para avaliar a capacidade do modelo de identificar corretamente os alunos em risco.

- **Precisão (*Dropout*):** Indica a proporção de alunos que o modelo previu como *Dropout* e que realmente evadiram. Uma alta precisão (como 0,85 na *Random Forest*) significa que, quando o modelo sinaliza um aluno em risco, ele está correto 85% das vezes, minimizando falsos positivos (intervenções desnecessárias).
- **Recall (*Dropout*):** Indica a proporção de alunos que evadiram e que o modelo conseguiu identificar corretamente. Um alto *recall* (como 0,77 na *Random Forest*) significa que o modelo é capaz de capturar a maioria dos casos de evasão, minimizando falsos negativos (alunos em risco que não foram identificados).

O modelo de *Random Forest* demonstrou o melhor desempenho em todas as métricas para a classe *Dropout*, alcançando um *F1-score* de 0,81. Isso sugere que a combinação de múltiplas árvores de decisão foi a mais eficaz para capturar a complexidade dos dados. Por outro lado, o SVM e a Rede Neural Artificial apresentaram os piores resultados, indicando que as configurações de hiperparâmetros escolhidas ou a natureza dos dados não favoreceram esses modelos.

4.5 Análise Comparativa dos Resultados

Os resultados obtidos neste estudo apresentam forte convergência com os achados de Kabathova e Drlik (2021), que também investigaram algoritmos de aprendizado de máquina para a predição de evasão estudantil. Assim como em nossa pesquisa, o *Random Forest* destacou-se como o modelo mais eficaz, alcançando os melhores indicadores de desempenho, com *F1-score* aproximado de 0,91 e acurácia de 93%. Essa convergência

reforça a robustez do *Random Forest* na captura de relações complexas e não lineares presentes em bases educacionais. Além disso, os autores também observaram desempenhos inferiores do SVM e da Rede Neural em comparação ao *Random Forest*, comportamento que se repete em nossos resultados, sugerindo que a eficácia desses modelos pode estar condicionada à natureza dos atributos e ao grau de variabilidade do conjunto de dados.

A análise dos resultados também revela similaridades e diferenças importantes em relação ao estudo conduzido por Sulak e Koklu (2024), que aplicaram *Decision Tree*, *Random Forest* e Rede Neural Artificial sobre um conjunto de dados multiclasse contendo mais de quatro mil estudantes. Embora nossa pesquisa tenha identificado o *Random Forest* como o modelo de melhor desempenho para a classe *Dropout*, o estudo citado apresenta um resultado distinto: a Rede Neural Artificial obteve a maior acurácia (77,3%) e o maior *F-score* (76,2%), superando o *Random Forest* e o *Decision Tree*. Essa divergência sugere que o comportamento relativo entre os algoritmos pode variar conforme a dimensionalidade, o balanceamento das classes e a riqueza informacional dos atributos disponíveis na base de dados. Ainda assim, ambos os trabalhos convergem ao indicar que modelos mais complexos — sejam eles baseados em múltiplas árvores ou em múltiplas camadas — tendem a superar métodos mais simples em cenários de classificação de evasão escolar.

5 CONCLUSÃO

O presente trabalho teve como objetivo analisar e comparar o desempenho de cinco algoritmos de aprendizado de máquina — *Decision Tree*, *Random Forest*, Regressão Logística, *Support Vector Machine* e Rede Neural Artificial — na tarefa de prever a evasão escolar a partir de um conjunto de dados educacionais proveniente do repositório *UC Irvine*. A proposta central consistiu em identificar qual modelo apresenta maior capacidade preditiva para auxiliar instituições de ensino na identificação precoce de estudantes em risco, contribuindo para ações preventivas mais direcionadas e eficazes.

Os resultados obtidos demonstraram que o modelo ***Random Forest*** apresentou o desempenho mais robusto e superior em todas as métricas de avaliação, especialmente para a classe de evasão (*Dropout*), alcançando um *F1-score* de 0,81. Este desempenho sugere que a abordagem de combinação de múltiplas árvores de decisão é a mais eficaz para capturar as relações não-lineares e a complexidade dos dados multifatoriais de evasão escolar. Modelos como SVM e a Rede Neural Artificial apresentaram desempenho inferior, possivelmente devido à configuração dos hiperparâmetros e às características da base utilizada. A análise exploratória também permitiu identificar padrões relevantes relacionados ao gênero, situação socioeconômica e fatores acadêmicos, reforçando a natureza multifatorial da evasão escolar.

Para trabalhos futuros, sugere-se a expansão desta pesquisa em diversas frentes. Primeiramente, a inclusão de técnicas avançadas de balanceamento de classes, como *SMOTE* ou *ADASYN*, pode ser explorada para mitigar o impacto do desbalanceamento nos resultados dos modelos menos eficazes. Em segundo lugar, a aplicação de técnicas de *feature engineering* mais sofisticadas, incorporando variáveis psicossociais ou econômicas adicionais, pode aprimorar ainda mais a capacidade preditiva. Por fim, recomenda-se a validação dos modelos em conjuntos de dados de diferentes instituições ou regiões geográficas, visando avaliar a generalização e a robustez das conclusões em contextos educacionais variados.

REFERÊNCIAS

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York, NY: Springer, 2009. 13

IBM. **O que é aprendizado supervisionado?** s.d. Acesso em: 27 maio 2025. Disponível em: <<https://www.ibm.com/br-pt/topics/supervised-learning>>. 12

IBM; STRYKER, C. **O que é inteligência artificial (IA)?** 2024. Acesso em: 27 maio 2025. Disponível em: <<https://www.ibm.com/br-pt/think/topics/artificial-intelligence>>. 11

KABATHOVA, J.; DRLIK, M. Towards predicting student 's dropout in university courses using different machine learning techniques. **Applied Sciences**, 2021. Acesso em: 30 abr. 2025. Disponível em: <<https://www.mdpi.com/2076-3417/11/7/3130>>. 9, 15, 16, 29

LINO, E. R. O. **A problemática da evasão escolar: uma revisão bibliográfica integrativa**. Dissertação (Mestrado) — Escola de Ciências Agrárias e Biológicas, Pontifícia Universidade Católica de Goiás, Goiânia, 2020. Monografia (Licenciatura em Ciências Biológicas) – Acesso em: 19 maio 2025. Disponível em: <<https://repositorio.pucgoias.edu.br/jspui/bitstream/123456789/728/1/Monografia%20II%20Ellen%20Ri%20CC%81zia%20VERSA%20O%20FINAL%20CORRIGIDA%20.pdf>>. 9, 15

OSISANWO, F. Y. et al. Supervised machine learning algorithms: Classification and comparison. **International Journal of Computer Trends and Technology**, 2017. Acesso em: 30 abr. 2025. Disponível em: <https://www.researchgate.net/publication/318338750_Supervised_Machine_Learning_Algorithms_Classification_and_Comparison>. 10, 11, 13, 14, 16

RUSSELL, S. J.; NORVIG, P. **Inteligência Artificial Uma abordagem moderna**. 3. ed. Rio de Janeiro: GEN LTC, 2013. Acesso em: 04 de junho de 2025. ISBN 978-8535237016. Disponível em: <[https://www.kufunda.net/publicdocs/Intelig%C3%A2ncia%20Artificial%20\(Peter%20Norvig,%20Stuart%20Russell\).pdf](https://www.kufunda.net/publicdocs/Intelig%C3%A2ncia%20Artificial%20(Peter%20Norvig,%20Stuart%20Russell).pdf)>. 12, 13, 14

Santillana Educação. **Evasão escolar: causas, consequências e como combater**. 2025. Santillana Educação. Acesso em: 19 maio 2025. Disponível em: <<https://www.santillanaeducacao.com.br/blog/evasao-escolar/>>. 9, 15

SINGLA, A. et al. The state of ai: How organizations are rewiring to capture value. **McKinsey & Company**, mar 2025. Acesso em: 12 maio 2025. Disponível em: <<https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>>. 9, 16

SULAK, S. A.; KOKLU, N. Predicting student dropout using machine learning algorithms. **Intell Methods Eng Sci**, 2024. Acesso em: 30 abr. 2025. Disponível em: <<https://imiens.org/index.php/imiens/article/view/62>>. 11, 16, 30